- ANALIZA SKŁADOWYCH GŁÓWNYCH

import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sb
from sklearn.decomposition import PCA

Załadowanie zbioru danych:

data=pd.read_csv('HR_comma_sep.csv')
data

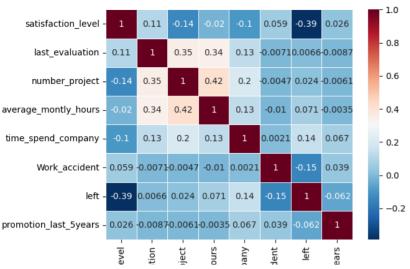
•	satisfaction_level	last_evaluation	number_project	average_montly_hours	time_spend_company	Work_accident	left	promo
0	0.38	0.53	2	157	3	0	1	
1	0.80	0.86	5	262	6	0	1	
2	0.11	0.88	7	272	4	0	1	
3	0.72	0.87	5	223	5	0	1	
4	0.37	0.52	2	159	3	0	1	
14994	0.40	0.57	2	151	3	0	1	
14995	0.37	0.48	2	160	3	0	1	
14996	0.37	0.53	2	143	3	0	1	
14997	0.11	0.96	6	280	4	0	1	
14998	0.37	0.52	2	158	3	0	1	

14999 rows x 10 columns

corr=data.corr()

/var/folders/wy/7w1mlgcx4vjfgbpvhlk2y7m00000gn/T/ipykernel_54143/2057684327.py:1: FutureWarning: The default value of numeric_only in DataFrame.corr is deprecated. In a future version, it will corr=data.corr()

<AxesSubplot: >



CorrMatrix = np.array(data.corr())
CorrMatrix

1.

[-0.38837498, 0.00656712, 0.02378719, 0.07128718, 0.14482217, -0.15462163, 1. , -0.06178811], [0.02560519, -0.00868377, -0.00606396, -0.00354441, 0.06743293, 0.03924543, -0.06178811, 1.]])

, -0.15462163, 0.03924543],

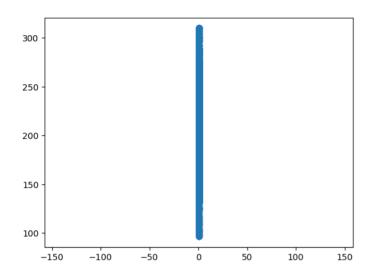
0.00212042, 0.14482217, 0.067432931,

[-0.10086607, 0.13159072, 0.19678589, 0.12775491, 1.

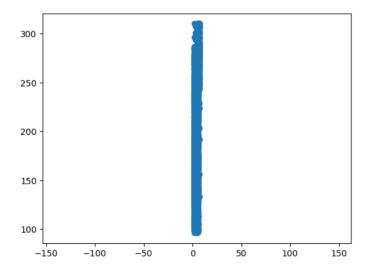
[0.05869724, -0.00710429, -0.00474055, -0.01014289, 0.00212042,

plt.scatter(data.iloc[:,1], data.iloc[:,2])
plt.axis('equal');
plt.show()

```
plt.scatter(data.iloc[:,1], data.iloc[:,3])
plt.axis('equal');
plt.show()
```



```
plt.scatter(data.iloc[:,2], data.iloc[:,3])
plt.axis('equal');
plt.show()
```



```
w, v = np.linalg.eig(CorrMatrix)
print(v)
    [1.86091589 1.46409354 0.47745185 1.06058666 0.95598374 0.8454993
    0.62648811 0.7089809 ]
    [[-0.18956186 -0.60825815 0.51043559 0.14578963 -0.2534991 -0.32268329
     -0.2910217 0.2433296 ]
    0.46363715 -0.31222881 -0.27367838 0.15715943 -0.10307248 -0.06471173
      0.54777287 0.52257837]
    0.24157676 -0.47335058]
    0.52559587 -0.17853674 -0.30588994 0.11339814 0.0120681 0.25349244
     -0.72147388 0.022742051
    0.33395132 0.11709262 -0.11038416 -0.44415687 -0.04569912 -0.79303045
     -0.09314767 -0.16013636]
    [-0.06443923 - 0.28140442 \ 0.07016424 - 0.42577604 \ 0.81315664 \ 0.06549289
     -0.02938544 0.253129081
    -0.16219105 0.58392171]
     [-0.00870881 - 0.11358933 \quad 0.03780465 - 0.74989628 - 0.50186771 \quad 0.39801173
      0.02283486 0.1115438711
v[:,0]
    array([-0.18956186, 0.46363715, 0.55704703, 0.52559587, 0.33395132,
          -0.06443923, 0.2163394, -0.00870881])
v[:,1]
    array([-0.60825815, -0.31222881, -0.12254292, -0.17853674, 0.11709262,
          -0.28140442, 0.61631274, -0.11358933])
v[:,2]
    array([ 0.51043559, -0.27367838, 0.58883958, -0.30588994, -0.11038416,
           0.07016424, 0.45356155, 0.037804651)
v[:,3]
    array([ 0.14578963, 0.15715943, 0.0129521 , 0.11339814, -0.44415687,
          -0.42577604, 0.01069646, -0.74989628])
v[:,4]
    array([-0.2534991 , -0.10307248, 0.09858338, 0.0120681 , -0.04569912,
           0.81315664, 0.00816191, -0.50186771])
v[:,5]
    array([-0.32268329, -0.06471173, 0.1887942, 0.25349244, -0.79303045,
           0.06549289, 0.01364792, 0.398011731)
v[:,6]
    array([-0.2910217 , 0.54777287, 0.24157676, -0.72147388, -0.09314767,
          -0.02938544, -0.16219105, 0.02283486])
```

▼ Dwie składowe główne

Wyliczamy dwie składowe główne (n_components=2) czyli wektory bazowe nowego układu współrzędnych:

Wektory bazowe nowego układu wpółrzędnych:

```
print(pca.components_)

[[-1.00033243e-04   1.16454569e-03   1.03016936e-02   9.99939075e-01
        3.73905642e-03   -7.14335346e-05   6.08072674e-04   -1.02220131e-05]
        [-2.22798744e-02   1.53049805e-02   2.71231022e-01   -6.43334035e-03
        9.61232600e-01   2.85025356e-04   4.06830170e-02   6.19745208e-03]]
```

Wariancje dla nowych współrzędnych:

```
print(pca.explained_variance_)
[2.49461695e+03 2.17485649e+00]
```

Dodajemy do wykresu wektory wyznaczające nowy układ współrzędnych. Ich długość określona jest przez wariancje:

```
def draw_vector(v0, v1, ax=None):
   ax = ax or plt.gca()
   arrowprops=dict(arrowstyle='->',
```

```
linewidth=2.
    shrinkA=0, shrinkB=0, color='black')
    ax.annotate('', v1, v0, arrowprops=arrowprops)
  pca.explained variance
      array([2.49461695e+03, 2.17485649e+00])
  #plt.scatter(data2.iloc[:, 0], data2.iloc[:, 4], alpha=0.2)
  #for length, vector in zip(pca.explained_variance_, pca.components_):
   # v = vector * 3 * np.sqrt(length)
   # draw vector(pca.mean , pca.mean + v)
  #plt.axis('equal');
  Współrzędne punktów w nowym układzie współrzędnych:
  data_pca = pca.transform(data2)
  data pca
      array([[-44.06780993, -0.65140796],
             [ 60.96825747, 2.36617527],
             [ 70.98086581, 0.93751792],
              [-58.06695598, -0.5611184],
              [ 78.97016987, 0.61604457],
              [-43.0678815 , -0.65777155]])
  plt.scatter(data_pca[:,0], data_pca[:,1])
  plt.axis('equal');
         80
         60
         40
         20
          0
        -20

▼ Jedna składowa główna
```

Wyliczamy jedną składową główną (n_components=1) - chcemy wyeliminować jeden wymiar danych.

-100pca = PCA(n components=1) pca.fit(data2)

-50

PCA PCA(n_components=1) Współrzędne punktów w nowym układzie współrzędnych:

```
data_pca = pca.transform(data2)
```

Porówanie kształtów danych początkowych i po redukcji jednego wymiaru:

```
print("Początkowy shape: ", data2.shape)
print("Po transformacji shape:", data_pca.shape)

Początkowy shape: (14999, 8)
Po transformacji shape: (14999, 1)
```

Dane początkowe i po redukcji wymiaru:

```
data_new = pca.inverse_transform(data_pca)
plt.scatter(data2.iloc[:, 1], data2.iloc[:, 2]),
plt.scatter(data_new[:, 0], data_new[:, 1]),
plt.axis('equal');
```

